



پروژه‌ی پایانی رایانش تکاملی

عنوان: نسخه‌ی بهبودیافته‌ی الگوریتم تکامل تفاضلی

استاد: آقای دکتر ملک

ارائه دهنده: پدram یزدی پور

شماره دانشجویی: ۹۹۴۴۳۲۴۱

اسفند ۱۴۰۰

فهرست مطالب

۳	توضیح الگوریتم.....
۴	تنظیم پارامترها.....
۷	راهنمای اجرای کد.....
۸	نتایج.....
۱۲	تحلیل نتایج.....
۱۳	جمع‌بندی.....

توضیح الگوریتم

این الگوریتم دو تفاوت با نسخه‌ی اصلی الگوریتم Differential Evolution دارد.

تفاوت اول: بردار جهش معرفی شده در این الگوریتم در معادله‌ی ۱ آمده است. X^g یک عضو از اعضای برتر جمعیت است که به صورت تصادفی انتخاب شده است. اعضای برتر جمعیت می‌تواند بین ۱ تا ۳۰ درصد، ۱۱ تا ۴۰ درصد، ۲۱ تا ۵۰ درصد یا ۳۱ تا ۶۰ درصد از شایسته‌ترین اعضا انتخاب شوند. X^1 و X^2 نیز به صورت کاملاً تصادفی از کل اعضا انتخاب می‌شوند. X_{best} نیز شایسته‌ترین عضو جمعیت است. تمامی اعضای دخیل در بردار جهش باید متمایز باشند. دو پارامتر F_1 و F_2 نیز باید تنظیم شوند.

$$V_i^g = X_{r_3}^g + F_1 \times (X_{best}^g - X_{r_3}^g) + F_2 \times (X_{r_1}^g - X_{r_2}^g) \quad \text{معادله‌ی ۱:}$$

تفاوت دوم: اجرای Opposition Learning به نحوی که به احتمالی تحت عنوان Jumping Rate برای هر عضو از جمعیت و برای هر ژن، مقدار آن ژن (الل) را از مجموع مقدار کمینه و بیشینه‌ی آن ژن بین کل اعضای جمعیت کم می‌کنیم و یک کروموزوم جدید می‌سازیم. در نهایت بهترین اعضا را میان اجتماع جمعیت اصلی و جمعیت جدید به نسل بعد راه می‌دهیم. استدلال مقاله برای معرفی این عملگر این است که ممکن است قرینه‌ی یک عضو با شایستگی پایین، شایستگی خیلی بیشتری داشته باشد و در واقع برای افزایش تنوع به کار می‌رود.

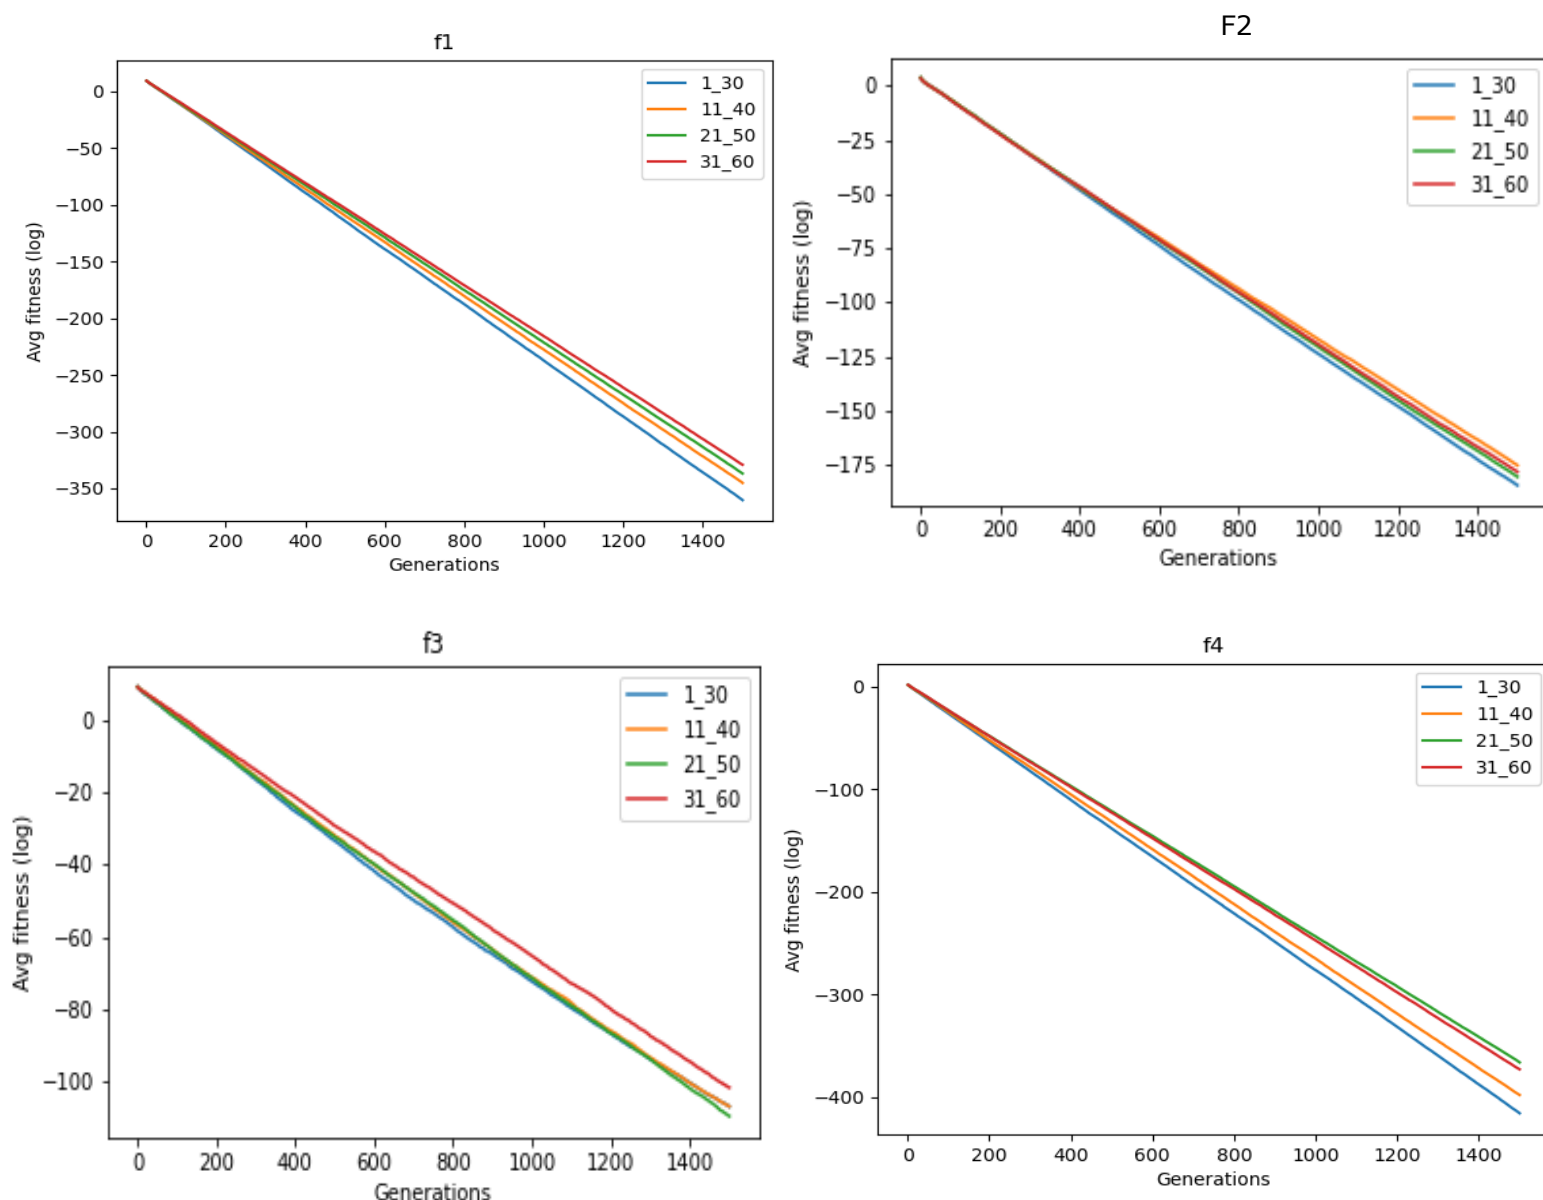
توابع ارزیابی

شکل ۱: توابع ارزیابی







Functions	S	f_{min}
$f_1(x) = \sum_{i=1}^D x_i^2$	$[-100, 100]^D$	0
$f_2(x) = \sum_{i=1}^D x_i + \prod_{i=1}^D x_i $	$[-10, 10]^D$	0
$f_3(x) = \sum_{i=1}^D \left(\sum_{j=1}^i x_j \right)^2$	$[-100, 100]^D$	0
$f_4(x) = \sum_{i=1}^D ix_i^2$	$[-1.28, 1.28]^D$	0
$f_5(x) = \sum_{i=1}^{D-1} (100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2)$	$[-30, 30]^D$	0
$f_6(x) = \sum_{i=1}^D (x_i^2 - 10 \cos \cos(2\pi x_i) + 10)$	$[-5.12, 5.12]^D$	0
$f_7(x) = -20 \exp \left(-0.2 \sum_{i=1}^D x_i \right) - \exp \left(\frac{\sum_{i=1}^D \cos(2\pi x_i)}{D} \right) + 20 + \exp(1)$	$[-32, 32]^D$	0
$f_8(x) = \frac{1}{4000} \sum_{i=1}^D x_i^2 - \prod_{i=1}^D \cos \left(\frac{x_i}{\sqrt{i}} \right) + 1$	$[-600, 600]^D$	0
$f_9(x) = \sum_{i=1}^D [x_i + 0.5]^2$	$[-100, 100]^D$	0
$f_{10}(x) = \sum_{i=1}^D ix_i^4 + \text{random}[0, 1)$	$[-1.28, 1.28]^D$	0
$f_{11}(x) = \sum_{i=1}^D x_i \sin(x_i) + 0.1x_i $	$[-10, 10]^D$	0
$f_{12}(x) = \sum_{i=1}^D x_i ^{(i+1)}$	$[-1, 1]$	0

تنظیم پارامترها

در مقاله یک جدول برای پارامترهای الگوریتم پیشنهاد شده است؛ هر چند در ارزیابی‌های انجام شده دریافتیم این پیشنهادات باید برای هر تابع مجدداً تنظیم شوند. یکی از پارامترهایی که متأسفانه چندان به تنظیم آن دقت نشده است و پس از ارائه‌ی نتایج نهایی راجع به انتخاب مقادیر آن تست‌هایی انجام شده مربوط به درصد اعضای برتر جمعیت برای انتخاب عضو X^3 است. به همین منظور، ابتدا روی تمام توابع چهار مقدار مختلف برای انتخاب اعضای برتر جمعیت را که توسط مقاله پیشنهاد شده با هم مقایسه می‌کنیم تا بعد از تعیین آن بتوانیم ارزیابی نهایی را انجام دهیم. شکل ۲ شامل ۱۲ نمودار است. محور قائم این نمودارها معرف میانگین لگاریتم شایستگی به ازای ۱۰ بار اجراست و محور افقی نیز شماره‌ی هر نسل است.




شکل ۲: نمودارهای میانگین فیتنس-نسل برای انتخاب همسایگی اعضای برتر جمعیت



۵

ادامه‌ی شکل ۲: نمودارهای میانگین فیتنس-نسل برای انتخاب همسایگی اعضای برتر جمعیت



ادامه ی شکل ۲: نمودارهای میانگین فیتنس-نسل برای انتخاب همسایگی اعضای برتر جمعیت

به جز نمودار تابع F_{10} که یک تابع نویزی است، برای بقیه ی توابع می توان درصد مناسب همسایگی اعضای برتر برای انتخاب عضو X^3 را تشخیص داد. مثلاً برای تابع F_{11} بهتر است عضو X^3 از بین ۳۱ تا ۶۰ درصد اعضای برتر جمعیت انتخاب شود. بعد از تعیین این پارامتر، برای بقیه ی پارامترها باید با سعی و خطا روی پارامترهای پیشنهادی توسط مقاله تنظیم شوند. جدول ۱ پارامترهای پیشنهادی مقاله را نشان می دهد. جدول ۲ نیز پارامترهای پیشنهادی این پروژه است که با توجه تعداد بسیار زیاد حالات ممکن، حالاتی که در آزمون و خطاها عملکرد خوبی داشته اند را (بدون تست تمام حالات ممکن) آورده ایم.

جدول ۱: پارامترهای پیشنهادی توسط مقاله

F1, F2	0.4
Jumping Rate	0.3
Crossover Factor	0.9
Generations	1500
Population	100

جدول ۲: پارامترهای پیشنهادی توسط پروژه‌ی حاضر

Parameters Functions	Scaling Factor 1	Scaling Factor 2	Jumping Rate	Crossover Rate	X3 Neighborhood
F1	۰.۵	۰.۲	۱	۰.۱	۱-۳۰
F2	۱	۰.۱	۱	۰.۱	۱-۳۰
F3	۰.۷	۰.۶	۱	۰.۵	۱-۳۰
F4	۰.۴	۰.۳	۱	۰.۲	۱-۳۰
F5	۰.۵	۰.۶	۱	۰.۱	۱۱-۴۰
F6	۰.۵	۰.۶	۱	۰.۱	۱-۳۰
F7	۰.۳	۰.۷	۰.۵	۰.۱	۱-۳۰
F8	۰.۳	۰.۵	۰.۵	۰.۱	۱-۳۰
F9	۰.۵	۰.۳	۱	۰.۱	۱-۳۰
F10	۰.۴	۰.۴	۱	۰.۲	No diff
F11	۰.۵	۰.۳	۱	۰.۱	۳۱-۶۰
F12	۱	۰.۲	۱	۰.۱	۱-۳۰

راهنمای اجرای کد

هم لینک گوگل کولب و هم فایل کد آورده شده است. برای اجرا، ابتدا باید پارامترها را تنظیم کنید. در اولین قسمت کد بعد از کتابخانه‌های لازم، می‌توانید هر پارامتری را مقداری کنید که در شکل ۴ آمده است.

```
#####===== PARAMETERS =====
cr = 0.1                #crossover rate
F1, F2 = 0.3 , 0.7     #scaling factors
jr = 0.5               #jumping rate
#dimensions = [10,30,50,100,200,500,1000]
dimension = 30
pop_size = 100
generations = 1500
function_number = 1     #index == function number (12 functions, 1-12)
```

شکل ۳: کد مربوط به مقداردهی پارامترهای الگوریتم

تمام پارامترهای موجود در شکل ۴ توضیح داده شده‌اند و برای مقداردهی آنها می‌توانید به جدول ۲ مراجعه کنید. برای انتخاب تابع هدف، متغیر `function_number` را بین ۱ تا ۱۲ مقدار دهید که هر کدام یک تابع بنچمارک است. توابع بنچمارک در شکل ۱ معرفی شده‌اند. لطفا مقدار صفر به این متغیر ندهید چون کد ارور خواهد داد.

تابع اصلی برای اجرای کد در شکل ۵ آمده است. این تابع دو ورودی دریافت می‌کند؛ اولی مربوط به درصد اعضای برتر جمعیت است که در شکل ۳ نمودارهای آن به طور کامل آمده است و باید اولین عدد هر مقدار وارد شود که در جدول ۳ آمده است.

```
#rank = [1,11,21,31]
execute(rank = 1, n_executions = 10)
|
```

شکل ۴: کد مربوط به تابع اصلی اجرای الگوریتم و ورودی‌های آن

پارامتر `n_executions` تعیین‌کننده‌ی تعداد دفعات اجرای الگوریتم برای ارزیابی نتایج است.

جدول ۳: نحوه‌ی دریافت ورودی پارامتر `rank` تابع اصلی کد

مقدار پارامتر <code>rank</code> برای تابع <code>execute()</code>	درصد اعضای برتر جمعیت برای انتخاب X^3
۱	۱-۳۰
۱۱	۱۱-۴۰
۲۱	۲۱-۵۰
۳۱	۳۱-۶۰

نتایج اجرای الگوریتم

نتایج اجرای الگوریتم روی تمام توابع ارزیابی در جدول ۴ قابل مشاهده است. فایل متنی این نتایج نیز با دقت اشراری بالاتر در فایل پروژه موجود است. ستونهای جدول ۴ شامل بهترین شایستگی، بدترین شایستگی، میانگین شایستگی‌ها، میانه‌ی شایستگی‌ها، متوسط زمان اجرا و انحراف معیار زمان اجرا بر حسب ثانیه است. علت در نظر گرفتن این فیلدها امکان مقایسه با نتایج مقاله است.

جدول ۴: نتایج اجرای الگوریتم روی ۱۲ تابع ارزیابی مختلف

F1	Best	Worst	Mean	Median	Avg(s)	Std(s)
۱۰	۴.۱۲e-۱۵۹	۱.۹۴e-۱۵۵	۴.۶۰e-۱۵۶	۱.۵۸e-۱۵۷	۴.۸۴	۰.۳۳
۳۰	۳.۴۲e-۵۱	۵.۰۹e-۴۹	۱.۹۲e-۴۹	۴.۴۵e-۵۰	۱۱.۲۷	۰.۵۵
۵۰	۲.۲۲e-۲۷	۵.۹۰e-۲۶	۱.۴۱e-۲۶	۳.۶۰e-۲۷	۱۶.۶۴	۰.۴۵
۱۰۰	۴.۴۲e-۰۹	۳.۲۸e-۰۸	۱.۶۳e-۰۸	۷.۹۳e-۰۹	۳۲.۴۸	۰.۸۱
۲۰۰	۳.۳۵	۶۱.۲۶	۱۶.۵۸	۵.۹۱	۶۷.۴۰	۴.۸۱
۵۰۰	۱۱۸۰۷.۳۶	۲۴۴۸۳.۵۶	۱۶۴۲۷.۲۳	۱۵۱۸۲.۹۳	۱۸۰.۳۵	۳.۳۸
۱۰۰۰	۱۳۴۵۵۳.۷۴	۱۶۰۹۰۲.۵۲	۱۴۷۷۵۵.۶	۱۵۰۹۴۵.۹	۳۷۹.۹۳	۲.۴۱
F2	Best	Worst	Mean	Median	Avg(s)	Std(s)
۱۰	۷.۳۹e-۸۶	۱.۶۰e-۸۳	۱.۰۴e-۸۳	۱.۵۳e-۸۳	۱۳.۴۲	۰.۶۳
۳۰	۱.۰e-۲۷	۳.۰۶e-۲۶	۱.۱۰e-۲۶	۱.۴۲e-۲۷	۳۴.۲۲	۱.۴۴
۵۰	۳.۲۰e-۱۶	۲.۰۲e-۱۵	۱.۲۸e-۱۵	۱.۵۰e-۱۵	۵۳.۱۴	۰.۱۹
۱۰۰	۰.۰۰۰۱۴	۰.۰۰۰۶۰	۰.۰۰۰۳۵	۰.۰۰۰۳۱	۱۰۴.۳۰	۰.۲۵
۲۰۰	۴.۵۶	۶.۸۸	۵.۵۳	۵.۱۴	۲۲۶.۲۴	۳.۴۹
۵۰۰	۳۰۹.۳۵	۳۷۸.۵۹	۳۴۵.۰۱	۳۴۷.۰۹	۵۵۸.۷۹	۱.۹۹
۱۰۰۰	inf	inf	inf	inf	۱۱۰۹.۱۱	۴۲.۶۶
F3	Best	Worst	Mean	Median	Avg(s)	Std(s)
۱۰	۷.۴۳e-۴۲	۲.۵۲e-۱۲	۸.۴۲e-۱۳	۵.۵۰e-۳۸	۶۳.۸۸	۱.۳۱
۳۰	۰.۰۰۱۰	۰.۰۴۹	۰.۰۱۸	۰.۰۰۳۹	۲۰۲.۶۱	۱.۳۰
۵۰	۳۵۱.۹۵	۶۲۷.۱۸	۵۲۶.۰۲	۵۹۸.۹۳	۳۵۶.۳۱	۰.۴۱۸
۱۰۰	۸۷۷۹۶.۰۱	۹۵۵۷۸.۴۳	۹۲۱۱۱.۲۶	۹۲۹۵۹.۳۳	۸۵۴.۷۷	۴.۵۲
۲۰۰	۳.۳۵	۶۱.۲۶	۱۶.۵۸	۵.۹۱	۶۷.۴۰	۴.۸۱
۵۰۰	۷۴۲۷۳۳.۸۷	۹۷۲۶۸۸.۹۲	۸۷۳۳۰۷.۷۲	۹۰۴۵۰۰.۳۸	۲۷۱۶.۲۸	۳۱۲.۸۷
۱۰۰۰						
F4	Best	Worst	Mean	Median	Avg(s)	Std(s)
۱۰	۷.۴۰e-۱۸۱	۹.۲۳e-۶۸	۴.۶۰e-۱۵۶	۴.۶۵e-۱۸۰	۹.۰۴	۱.۱۷
۳۰	۱.۳۶e-۶۵	۴.۳۶e-۶۰	۱.۴۷e-۶۰	۷.۲۱e-۶۲	۱۰.۱۳	۲.۲۷
۵۰	۱.۳۴e-۳۲	۱.۸۴e-۲۴	۶.۱۴e-۲۵	۱.۰۶e-۳۰	۱۳.۵۷	۰.۰۵
۱۰۰	۱.۳۶e-۱۱	۰.۰۲۶	۰.۰۰۸	۸.۶۱e-۰۹	۲۷.۱۹	۰.۴۱
۲۰۰	۰.۰۱۹	۰.۲۰۸	۰.۱۳۴	۰.۱۷۴	۵۸.۳۱	۰.۴۷۹
۵۰۰	۶۳۸.۹۹	۱۰۲۷.۵۳	۸۳۲.۳۳	۸۳۰.۴۶	۱۵۸.۱۹	۰.۸۶۸

1...	1.989.31	16836.71	13333.89	12175.64	324.10	3.753
F5	Best	Worst	Mean	Median	Avg(s)	Std(s)
1.	2.95e-15	3.98	1.32	1.61e-14	8.98	0.21
3.	1.62	28.59	17.48	13.21	22.88	0.65
5.	38.34	39.25	38.84	38.94	36.01	0.39
10.	92.94	147.29	111.32	93.71	72.41	0.32
20.	284.04	318.42	299.17	295.07	149.73	1.53
50.	5243.83	12561.88	8276.22	7022.943	394.69	1.55
100.	1012993.08	1412800.50	1198057.31	1168378.36	8080.91	2.05
F6	Best	Worst	Mean	Median	Avg(s)	Std(s)
1.	8.94	0.67
3.	19.78	0.17
5.	54.26	57.70	55.82	55.49	32.07	0.38
10.	370.99	388.19	377.41	373.03	65.77	0.88
20.	1199.26	1228.14	1210.73	1204.79	135.68	1.09
50.	4356.51	4502.48	4409.51	4369.533	343.31	0.757
100.	10426.309	10627.76	10555.49	10612.42	691.49	2.73
F7	Best	Worst	Mean	Median	Avg(s)	Std(s)
1.	3.99e-15	3.99e-15	3.99e-15	3.99e-15	7.901	0.95
3.	2.24e-12	4.75e-12	3.42e-12	3.42e-12	16.76	0.05
5.	1.11e-07	4.24e-07	2.78e-07	2.57e-07	26.654	0.62
10.	0.0026	0.0037	0.0031	0.0031	52.75	0.606
20.	1.49	1.68	1.58	1.58	10.664	1.16
50.	8.71	9.37	9.09	9.07	269.05	1.858
100.	14.32	15.22	14.68	14.65	530.54	4.38
F8	Best	Worst	Mean	Median	Avg(s)	Std(s)
1.	.	0.123	0.04	.	7.26	0.21
3.	17.89	0.70
5.	28.64	0.45
10.	1.003e-12	3.16e-12	2.067e-12	2.03e-12	57.80	1.13
20.	0.151	0.396	0.239	0.172	116.21	1.29

500	7.36	9.60	8.28	7.86	30.840	2.01
1000	178.08	208.299	191.594	188.39	636.50	5.74
F9	Best	Worst	Mean	Median	Avg(s)	Std(s)
10	3.18	0.02
30	.	3.08e-33	1.02e-33	.	7.60	0.017
50	3.81e-28	6.74e-27	2.82e-27	1.34e-27	12.24	0.062
100	6.21e-10	2.10e-09	1.31e-09	1.22e-09	24.81	0.487
200	0.500	2.82	1.721	1.84	52.84	0.41
500	11747.190	16464.64	14289.05	14655.34	149.47	0.37
1000	124774.9	133334.9	128410.802	127122.5	315.100	0.568
F10	Best	Worst	Mean	Median	Avg(s)	Std(s)
10	2.24	3.24	2.58	2.27	5.31	0.03
30	11.54	12.90	12.19	12.12	13.35	0.06
50	18.87	20.63	19.84	20.03	22.08	0.367
100	43.91	45.89	44.79	44.58	44.738	0.49
200	94.32	97.42	96.25	97.00	93.31	0.56
500	391.05	452.57	415.55	403.03	247.16	0.37
1000	2812.43	3423.47	3138.69	3180.16	516.820	1.19
F11	Best	Worst	Mean	Median	Avg(s)	Std(s)
10	1.76e-122	3.73e-93	1.24e-93	1.17e-106	31.06	5.21
30	8.46e-32	6.10e-16	2.03e-16	5.37e-30	67.81	0.67
50	6.83e-16	1.72e-15	1.03e-15	7.04e-16	111.71	0.55
100	3.99e-07	2.75e-06	1.46e-06	1.22e-06	223.58	0.807
200	0.015	0.110	0.057	0.0458	449.79	3.85
500	23.47	30.37	26.27	24.96	1127.285	1.742
1000	247.79	249.00	248.21	247.84	2280.47	0.64
F12	Best	Worst	Mean	Median	Avg(s)	Std(s)
10	3.07e-320	2.08e-301	2.08e-302	3.91e-314	12.21	0.39
30	2.07e-113	4.40e-90	4.40e-91	3.44e-98	33.15	0.90
50	2.09e-50	8.00e-20	8.13e-21	1.37e-26	54.93	1.25
100	3.55e-18	2.39e-10	4.76e-11	7.61e-13	117.76	9.52

۲۰۰	$2.22e-13$	$1.06e-07$	$1.07e-08$	$2.73e-11$	۲۲۳.۵۸	۴.۲۷
۵۰۰	$8.93e-14$	$4.14e-09$	$4.54e-10$	$1.09e-11$	۵۹۶.۵۷۶	۲۲.۶۵

تحلیل نتایج

به طور کلی با ارزیابی این الگوریتم دریافتیم در ابعاد بالا (۲۰۰، ۵۰۰ و ۱۰۰۰) تعداد جمعیت ۱۰۰ و تعداد نسل ۱۵۰۰ فرصت کافی برای بهینه شدن الگوریتم به دست نمی‌دهد و نتایج مقاله کمی عجیب است چون با ادامه دادن بهینه‌سازی برای بیشتر از ۱۵۰۰ نسل می‌توان پاسخهای بهتری گرفت.

نکته‌ی مهم دیگر آن که متاسفانه در هیچکدام از توابع بنچمارک موفق نشدیم به ازای پارامترهای پیشنهاد شده‌ی مقاله که در جدول ۱ نیز آمده است، نتایج خوبی کسب کنیم. اگر نویسندگان مقاله به ازای هر تابع از مجموعه پارامترهای متفاوتی بهره برده‌اند بهتر بود در متن مقاله ذکر می‌کردند.

توابع Multi Modal

الگوریتم مذکور در بهینه‌سازی تابع چندمداله‌ی Rosenbrock تا بعد ۱۰۰ نسبت به مقاله بهتر عمل کرده است. در تابع Rastrigin تا بعد ۵۰ کاملاً بهتر عمل کرده است اما در ابعاد سه رقمی به همان علت کافی نبودن تعداد نسل نتوانسته مانند مقاله جواب بگیرد؛ ما تعداد نسل و جمعیت را دقیقاً مثل مقاله در نظر گرفتیم تا امکان مقایسه‌ی دقت‌ها فراهم باشد. در تابع Ackley در هیچ بعدی جوابی بهتر از مقاله نگرفتیم اما جوابها در ابعاد پایین به جوابهای مقاله نزدیک است و حتی در بعد ۱۰ انحراف معیار بهترین جوابها صفر است. در تابع Griewank فقط در ابعاد دو رقمی موفق شدیم پاسخ بهینه‌ی سراسری (صفر) را بیابیم اما در ابعاد بالاتر گویا باید جستجو ادامه می‌یافته است.

توابع Uni Modal

در تابع F1 مقاله در تمام ابعاد جواب صفر را یافته است اما در این پروژه در بعد ۱۰ جوابی بسیار کوچک یافتیم و هر چه ابعاد بالاتر می‌رود جوابها از صفر بیشتر فاصله می‌گیرند. در باقی توابع تک حالتی نیز جوابها تقریباً به همین صورت هستند؛ مجدداً بازگو می‌کنیم که علت فاصله داشتن جوابها خصوصاً در توابع تک‌حالتی به خاطر تعداد نسل کم در مقابل ابعاد بزرگ مثل ۱۰۰۰ یا ۵۰۰ است و جوابهایی که مقاله گزارش کرده است، عجیب به نظر می‌رسند.

جمع‌بندی

در این الگوریتم یک روش یادگیری Opposition برای افزایش Diversity و بردار جهشی نوین برای افزایش فشار انتخاب معرفی شده‌اند تا از هر دو جهت الگوریتم بتواند خوب عمل کند. این الگوریتم بر خلاف ادعاهای مقاله موفق شد در بهینه‌سازی توابع چندحالتی در ابعاد پایین خوب عمل کند اما در ابعاد بالا نیاز به نسل بیشتری برای رسیدن به جوابهایی نزدیک آنچه مقاله گزارش داده دارد. در توابع تک‌حالتی نتوانستیم دقتهایی به خوبی مقاله بیابیم. انتقادی که به روش کار مقاله‌ی مذکور وارد است این است که ابتدا توابع ارزیابی را اجرا نموده سپس به دنبال یافتن پارامتر مربوط به همسایگی برای X^3 رفته در حالی که بهتر بود ابتدا تمام پارامترها تنظیم می‌شدند و سپس خروجی نهایی گرفته می‌شد. نقد دیگری که می‌توان به این مقاله وارد آورد این است که به ازای پارامترهای پیشنهادی آن هرگز نمی‌توان به جوابهایی مناسب رسید و باید دید هدف نویسندگان محترم از ارائه‌ی چنین مقادیری برای پارامترهای اصلی این الگوریتم چه بوده است.

مقاله

Deng, Wu, Shifan Shang, Xing Cai, Huimin Zhao, Yingjie Song, and Junjie Xu. "An improved differential evolution algorithm and its application in optimization problem." *Soft Computing* 25, no. 7 (2021): 5277-5298.